

基于 DCGAN 的图像生成研究

神经网络课程结课汇报

谢其虎 BA25219020 蒋世航 SA25219035 陈乐韬 SC25219109

中国科学技术大学

2026 年 6 月 14 日

目录

- 1 研究背景与动机
- 2 理论基础
- 3 实验设置与实现细节
- 4 实验结果与分析
- 5 总结与展望

- 1 研究背景与动机
- 2 理论基础
- 3 实验设置与实现细节
- 4 实验结果与分析
- 5 总结与展望

1.1 生成模型的发展

- ▶ **生成对抗网络 (GANs)**: Ian Goodfellow 于 2014 年提出。
- ▶ **核心思想**: 生成器与判别器相互博弈, 逐步学习真实数据分布。
- ▶ **应用场景**: 图像超分辨率、风格迁移、数据增强、视频预测等。
- ▶ **课程目标**: 复现并改进 DCGAN, 分析其在 CIFAR-10 上的表现。

参考工作

“Generative Adversarial Nets”, NIPS 2014

1.2 GAN 的演进与 DCGAN 结构

- ▶ **Vanilla GAN**: 基于全连接层搭建, 无卷积结构, 训练不稳定、易模式崩塌, 本课题仅作理论对比, 未复现。
- ▶ **DCGAN (本课题核心基线)**: 引入卷积结构, 使用 BatchNorm, 训练稳定, 适合图像。
- ▶ **WGAN-GP**: 引入 Wasserstein 距离与梯度惩罚, 理论缓解模式崩塌, 但收敛速度慢, 纳入本次消融对照。
- ▶ **Conditional GAN**: 加入类别标签 y , 实现可控生成, 但优化难度大, 仅作为后续改进思路。

为什么选择 DCGAN?

1. **结构适配**: 卷积操作天然契合图像的平移不变性。
2. **稳定性**: 结合转置卷积上采样、LeakyReLU 激活与判别器直接输出 logit, 并配合 BatchNorm 稳定训练。
3. **基线价值**: 是理解后续所有 GAN 变体的基石。




图 1: DCGAN 生成器与判别器完整网络结构

1.3 项目主要工作

核心工作

- ▶ 基线复现：搭建 DCGAN、WGAN-GP、CNN 条件 GAN、ResNet 条件 GAN 四套完整训练框架
- ▶ 消融实验：对比通道数、损失函数、EMA、DiffAugment 等多类策略的生成效果
- ▶ 量化评估：基于 FID 与 IS 双指标，完成所有模型的统一标准化评测
- ▶ 定性分析：生成样本网格、类别展示图、损失曲线等多维度可视化结果

核心成果

1. 最优配置：160 通道 DCGAN + BCE 损失，FID=**31.678**，IS=**5.872**
2. 相对基线：FID 下降 **17.3%**，IS 提升 **9.9%**
3. 核心结论：CIFAR-10 低分辨率场景下，加宽简易 DCGAN 优于复杂 ResNet 与 WGAN-GP




图 2: 整体训练与评估流水线

目录

- 1 研究背景与动机
- 2 理论基础**
- 3 实验设置与实现细节
- 4 实验结果与分析
- 5 总结与展望

2.1 生成器 (Generator) 设计

核心设计：学习潜在噪声到图像的映射 $G: Z \mapsto X$

- ▶ **输入映射**：将 128 维随机噪声 $z \sim \mathcal{N}(0, 1)$ 通过 4×4 转置卷积映射为高维特征图，作为卷积上采样起点。
- ▶ **逐级上采样**：共 4 层转置卷积，通过 3 次尺寸翻倍 ($4 \rightarrow 8 \rightarrow 16 \rightarrow 32$) 逐步还原分辨率。
- ▶ **归一化策略**：除输出层外，每层均使用 Batch Normalization，加速收敛并稳定训练分布。

关键实现细节

- ▶ 中间层统一使用 ReLU 激活，输出层使用 **Tanh** 激活，将像素值限制在 $[-1, 1]$ ，与真实图像预处理分布对齐。
- ▶ 权重初始化：卷积层服从 $\mathcal{N}(0, 0.02^2)$ ，BN 层权重均值为 1、偏置为 0。
- ▶ 实验变量：基础通道数设为可调参数，对比了 64/96/128/160 四档配置。

层级	操作	输出尺寸
输入	随机噪声向量	128
Layer 1	T-Conv + BN + ReLU	$4 \times 4 \times 512$
Layer 2	T-Conv + BN + ReLU	$8 \times 8 \times 256$
Layer 3	T-Conv + BN + ReLU	$16 \times 16 \times 128$
输出层	T-Conv + Tanh (无 BN)	$32 \times 32 \times 3$

表 1: 生成器层级配置 (基线 ch=64)

2.2 判别器 (Discriminator) 设计

核心设计：学习图像真假判别映射 $D : x \mapsto score$

- ▶ **输入输出：**输入真实/生成图像 x ，输出未归一化 logits（无 Sigmoid），作为真假判别分数。
- ▶ **逐级下采样：**共 4 层步长卷积，通过 3 次尺寸减半 ($32 \rightarrow 16 \rightarrow 8 \rightarrow 4$) 逐步压缩特征。
- ▶ **归一化策略：**除输入层与输出层外，中间层使用 Batch Normalization，稳定训练梯度。

关键实现细节

- ▶ 中间层统一使用 $\text{LeakyReLU}(\alpha = 0.2)$ 激活，保留负半轴梯度，避免梯度稀疏。
- ▶ 输入层不加 BN：防止初始训练时梯度剧烈震荡，符合 DCGAN 标准设计准则。
- ▶ 权重初始化：卷积层服从 $\mathcal{N}(0, 0.02^2)$ ，与生成器规则完全一致。
- ▶ 损失配合：logits 直接输入 BCEWithLogitsLoss ，数值稳定性优于显式 Sigmoid。

层级	操作	输出尺寸
输入	RGB 图像	$32 \times 32 \times 3$
Layer 1	Conv + LeakyReLU (无 BN)	$16 \times 16 \times 64$
Layer 2	Conv + BN + LeakyReLU	$8 \times 8 \times 128$
Layer 3	Conv + BN + LeakyReLU	$4 \times 4 \times 256$
输出层	Conv (无激活)	1 维 logit

表 2: 判别器层级配置（基线 ch=64）

2.3 备选损失函数对比

对比方案 1: LSGAN 最小二乘损失

$$L_G = \frac{1}{2} \mathbb{E} \left[(D(G(z)) - 1)^2 \right]$$

- ▶ 基于 Pearson χ^2 散度构建损失, 缓解判别器饱和导致的梯度消失
- ▶ 设计目标: 改善原始 BCE 损失训练不稳定、梯度易断层的问题
- ▶ 消融结论: 生成效果未超过 BCE 基线, 未作为最终方案

对比方案 2: WGAN-GP (探索性实验)

$$L_D = \underbrace{\mathbb{E}[D(\tilde{x})] - \mathbb{E}[D(x)]}_{\text{Wasserstein 距离}} + \underbrace{\lambda \mathbb{E} \left[(\|\nabla_{\hat{x}} D(\hat{x})\|_2 - 1)^2 \right]}_{\text{梯度惩罚}}$$

- ▶ 梯度惩罚强制满足 Lipschitz 约束, 理论上可缓解模式崩塌
- ▶ 实验设置: $n_{critic} = 5$, $\lambda = 10$, Adam
 $\beta_1 = 0.0$, $\beta_2 = 0.9$
- ▶ 相同轮次下生成质量弱于 BCE 基线, 且收敛速度更慢

2.4 条件 GAN 架构探索

基础 CNN 条件 GAN

$$\min_G \max_D V(D, G) = \mathbb{E}_x[\log D(x|y)] + \mathbb{E}_z[\log(1 - D(G(z|y)))]$$

- ▶ 核心设计：生成器与判别器输入端嵌入类别标签 y ，实现可控类别生成
- ▶ 网络架构：沿用 DCGAN 卷积 backbone，与基线模型结构对齐
- ▶ 实验定位：作为架构对照，验证条件约束对生成质量的影响

ResNet 条件 GAN（拓展探索）

$$H(x) = F(x) + x$$

- ▶ 核心改进：将普通卷积替换为残差块，通过跳层连接加深网络
- ▶ 配套策略：搭配 DiffAugment 数据增强与生成器 EMA 平滑策略
- ▶ 实验定位：探索深度残差架构在低分辨率生成任务上的表现

2.5 基准 BCE 损失与最终选型

BCE 损失原理与公式

基于 JS 散度的二元交叉熵，是原始 GAN 与 DCGAN 的默认损失函数：

$$\min_G \max_D V(D, G) = \mathbb{E}_x[\log D(x)] + \mathbb{E}_z[\log(1 - D(G(z)))]$$

- ▶ 判别器：学习区分真实/生成样本，完成标准二分类任务
- ▶ 生成器：最小化生成样本被判别为假的概率，逼近真实数据分布

最终选型结论

- ▶ 工程端采用 BCEWithLogitsLoss 实现，保证训练数值稳定性
- ▶ 搭配 Adam 优化器 ($\beta_1 = 0.5$, $\beta_2 = 0.999$) 与生成器 EMA 平滑策略
- ▶ 100 epoch 下取得最优 FID=31.678，效果显著优于 LSGAN 与 WGAN-GP
- ▶ 作为本课题所有通道消融实验的基准损失函数

目录

- 1 研究背景与动机
- 2 理论基础
- 3 实验设置与实现细节**
- 4 实验结果与分析
- 5 总结与展望

3.1 数据集与预处理

CIFAR-10 数据集

- ▶ 共 60,000 张 32×32 彩色图像，分 10 个类别
- ▶ 训练集 50,000 张，测试集 10,000 张，每类样本均衡
- ▶ 训练集用于模型学习，测试集作为 FID 计算的真实分布基准

预处理流程

- ▶ PIL 图像转换为 Tensor 格式
- ▶ 像素值归一化至 $[-1, 1]$ ，与生成器输出范围保持一致
- ▶ 基线配置：随机水平翻转，增强模型泛化能力
- ▶ 消融实验组：追加 DiffAugment 策略，验证数据增强对生成质量的增益

airplane

automobile

bird

cat

deer

dog

frog

horse

ship

truck




图 3: CIFAR-10 数据集样本示例

3.2 训练超参数配置

模型配置说明

- ▶ 共复现三类 GAN 损失函数，配套不同优化策略
- ▶ 条件 GAN 基于 DCGAN 架构扩展，新增类别嵌入分支
- ▶ 所有模型共享基础数据配置与输入输出维度

训练策略说明

- ▶ 基线快速验证用 50 轮，最优模型充分训练 100 轮
- ▶ EMA 仅平滑生成器参数，提升采样稳定性
- ▶ WGAN-GP 用梯度惩罚强制 Lipschitz 约束

参数分类	配置详情
通用基础参数	
Batch Size	128
噪声维度	128 维
生成图像尺寸	32×32
基础通道数	基线 64 / 最优 160
分模型优化器参数	
DCGAN / LSGAN	Adam, lr=0.0002, $\beta_1=0.5$, $\beta_2=0.999$
WGAN-GP	Adam, $\beta_1=0.0$, $\beta_2=0.9$, $n_{critic}=5$, $\lambda=10$
条件 GAN	沿用 DCGAN 优化配置，新增类别嵌入
训练策略参数	
训练轮数	基线 50 epoch / 最优 100 epoch
EMA 平滑	衰减系数 0.999，仅作用于生成器
梯度约束	WGAN-GP 采用梯度惩罚替代权重裁剪

表 3: 主要训练超参数汇总

3.3 评价指标

FID (Fréchet Inception Distance)

$$\text{FID} = \|\mu_r - \mu_g\|_2^2 + \text{Tr}(\Sigma_r + \Sigma_g - 2(\Sigma_r \Sigma_g)^{1/2})$$

- ▶ 核心思想：在 Inception-v3 特征空间比较真实与生成分布的距离
- ▶ 衡量维度：同时评估真实性与多样性，值越低越好
- ▶ 优势：对模式崩塌敏感，是生成任务的主流黄金指标

IS (Inception Score)

$$\text{IS} = \exp(\mathbb{E}_{x \sim p_g} \text{KL}(p(y|x) \parallel p(y)))$$

- ▶ 核心思想：基于 Inception-v3 分类置信度评估生成质量
- ▶ 衡量维度：图像清晰度 + 类别多样性，值越高越好
- ▶ 局限：无法检测模式崩塌，需与 FID 配合使用

本实验评估设置

- ▶ 采用预训练 Inception-v3 模型，提取 2048 维特征向量
- ▶ 每次采样 5000 张生成图像计算指标，重复 3 次取平均值
- ▶ 以 FID 为核心评价指标，IS 作为辅助参考

目录

- 1 研究背景与动机
- 2 理论基础
- 3 实验设置与实现细节
- 4 实验结果与分析**
- 5 总结与展望


4.1 训练过程可视化（通道消融 Loss 对比）

通道容量影响规律

- ▶ 四组训练全程稳定，判别器 Loss 无持续归零，无模式崩塌风险
- ▶ 统一趋势：生成器 Loss 先骤降、中期博弈震荡、后期缓慢抬升收敛
- ▶ 通道数越高，生成器稳态 Loss 越高，判别器判别能力同步增强
- ▶ Loss 仅作训练过程监控，最终生成质量以 FID 量化指标为准

实验结论

提升通道容量可增强模型特征学习能力；160 通道配置在 100epoch 训练下，生成质量与 FID 指标均达到最优。



Loss 子图分区：左上 ch=64 | 右上 ch=96 | 左下 ch=128 | 右下 ch=160（最优）

图 4: 不同基础通道数 DCGAN 训练 Loss 曲线对比

4.2 不同通道数生成效果对比

样本定性对比分析

- ▶ ch=64 (基线): 图像模糊, 物体边缘、纹理细节丢失严重
- ▶ ch=96 / ch=128: 清晰度逐步提升, 色彩与轮廓区分度改善
- ▶ ch=160 (最优): 物体边缘锐利, 类别多样性充足, 无模式崩塌

通道消融结论

提升生成器基础通道数可增强特征建模能力; 160 通道配置生成图像清晰度、多样性最优。

生成样本分区说明:

左上网格: ch=64 (基线)

右上网格: ch=96

左下网格: ch=128

右下网格: ch=160 (最优)




图 5: 不同通道配置生成样本网格对比

4.3 定量实验结果

指标与消融变量解读

- 评价指标：FID 越低、IS 越高，代表图像生成质量越好
- 对比 1（损失函数）：同 64 通道，BCE 优于 Wasserstein，WGAN-GP 生成效果更差
- 对比 2（EMA 平滑）：64 通道下，加入 EMA 可降低 FID、提升 IS
- 对比 3（通道宽度消融）：64-128-160 通道，FID 持续下降、IS 稳步上升

方法	训练轮数	关键设置	FID ↓	IS ↑
DCGAN baseline	50	BCE, ch=64	38.290	5.346 ± 0.159
WGAN-GP	50	n_critic=5, GP=10	74.674	3.636 ± 0.144
Conditional GAN	100	CNN conditional, ch=64	45.271	4.724 ± 0.157
ResNet Conditional GAN	150	ResNet + DiffAugment + EMA, ch=128	66.549	4.294 ± 0.134
ResNet Conditional GAN	200	ResNet + DiffAugment + EMA, ch=128	73.187	4.189 ± 0.127
DCGAN + LSGAN + DiffAugment + EMA	100	ch=64	41.796	5.163 ± 0.168
DCGAN + BCE + EMA	100	ch=64	34.040	5.432 ± 0.147
DCGAN + BCE + EMA	100	ch=64, raw generator	33.837	5.456 ± 0.183
DCGAN + BCE + EMA	100	ch=96, EMA generator	33.656	5.691 ± 0.171
DCGAN + BCE + EMA	100	ch=96, raw generator	34.168	5.589 ± 0.167
DCGAN + BCE + EMA	100	ch=128, raw generator	32.601	5.834 ± 0.141
DCGAN + BCE + EMA	100	ch=128, EMA generator	32.842	5.851 ± 0.225
DCGAN + BCE + EMA	100	ch=160, raw generator	31.678	5.872 ± 0.161
DCGAN + BCE + EMA	100	ch=160, EMA generator	32.216	5.869 ± 0.243

表 4: 不同 GAN 配置在 CIFAR-10 上的生成性能对比

定量综合结论

在 DCGAN+EMA、BCE 损失框架下，增大生成器通道宽度可显著优化生成分布；160 通道模型取得最优量化指标 FID=31.678，与 Loss 曲线、样本视觉结论完全吻合。

4.4 局限性

模型现存局限

1. 生成图像分辨率较低，细节仍然模糊。
2. 无条件 GAN 不能直接指定类别。
3. 动物类别存在语义混淆，如 cat、dog、deer、horse。
4. 未进行大规模超参数搜索。
5. FID 与 IS 不能完全替代人工视觉判断。




图 6: 基线生成的模糊样本

目录

- 1 研究背景与动机
- 2 理论基础
- 3 实验设置与实现细节
- 4 实验结果与分析
- 5 总结与展望**

5.1 课程总结

核心成果

- ▶ 完整复现 DCGAN 基线与全流程代码。
- ▶ 完成损失函数、模型容量、训练策略等对比实验。
- ▶ 最优模型 FID 达 31.678，相比基线下降 17.3%。
- ▶ IS 提升 9.9%，验证模型容量的正向作用。

主要收获

- ▶ 深入理解 GAN 博弈论原理与训练难点。
- ▶ 掌握 PyTorch 生成模型构建与调试流程。
- ▶ 明确网络宽度对生成质量的重要影响。
- ▶ 总结不同训练策略的适用场景与局限。

5.2 未来改进方向

- ▶ **超参数调优**：系统调参 ResNet、DiffAugment、WGAN-GP 等策略。
- ▶ **条件生成**：优化条件 GAN 稳定性，实现可控类别生成。
- ▶ **画质提升**：改进上采样结构，缓解棋盘格伪影，探索更高分辨率。
- ▶ **评价完善**：补充精度-召回率、主观评价等多维指标。

感谢聆听，欢迎提问！

小组分工

1. 代码开发与报告撰写：谢其虎 BA25219020
2. 答辩 PPT 制作：陈乐韬 SC25219109
3. 现场答辩汇报：蒋世航 SA25219035